


شرح جامع تحلیل ترنسکریپتومیکس فضایی در گلیوبلاستوما
توضیح گام‌به‌گام کد، منطق روش‌ها، تفسیر خروجی‌ها و ملاحظات محاسباتی



پروژه: Spatial Transcriptomic Analysis of Glioblastoma

تهیه‌شده بر اساس کد و خروجی‌های Notebook ارائه‌شده

نمای کلی پروژه

مقدار	ویژگی
10x Genomics Visium Spatial Transcriptomics	نوع داده
Human Glioblastoma	بافت
Spot × 36601 Gene 3468	ابعاد اولیه
Spot × 18618 Gene 2870	ابعاد پس از فیلتر
Leiden - 11 clusters	خوشه‌بندی
SpatialDE روی HVG 2000	تحلیل فضایی ژن

جریان کلی تحلیل

Visium GBM Data → QC → Filtering → Normalization/Log1p → HVG → PCA → Neighbors → UMAP → Leiden → Differential Expression → Spatial Mapping → SpatialDE → Literature-guided Gene Visualization

چکیده و تعریف مسئله

این پروژه یک تحلیل محاسباتی از داده‌های ترنسکریپتومیکس فضایی گلیوبلاستوما است. مسئله اصلی این است که بافت گلیوبلاستوما از نظر مولکولی یکنواخت نیست و نقاط مختلف یک مقطع بافتی می‌توانند الگوهای بیان ژنی متفاوتی داشته باشند. در RNA-seq معمولی، اطلاعات مکانی از بین می‌رود؛ اما در فناوری 10x Genomics Visium، برای هر نقطه یا Spot علاوه بر پروفایل بیان ژن، مختصات مکانی آن روی تصویر بافت نیز وجود دارد. بنابراین می‌توان پرسید کدام نواحی بافت از نظر ترنسکریپتومی به هم شبیه‌اند، چه خوشه‌هایی در داده شکل می‌گیرند، این خوشه‌ها در تصویر واقعی بافت کجا قرار دارند و چه ژن‌هایی الگوی بیان فضایی معنادار دارند.

این Notebook از روش‌های استاندارد زیست‌محاسباتی و آمار فضایی استفاده می‌کند و شامل یادگیری عمیق، CNN، Transformer یا GNN نیست. بخش‌های اصلی شامل کنترل کیفیت، فیلتر کردن Spot‌ها و ژن‌ها، نرمال‌سازی، انتخاب ژن‌های بسیار متغیر، PCA، ساخت گراف همسایگی، خوشه‌بندی Leiden، تحلیل بیان افتراقی، نمایش فضایی ژن‌ها و در نهایت SpatialDE برای یافتن ژن‌های Spatially Variable است. در انتها نیز پنج ژن گزارش شده در یک مطالعه قبلی مربوط به زیرنوع‌های GBM به‌صورت اکتشافی روی بافت نمایش داده می‌شوند.

۱. بارگذاری داده و ساختار AnnData

تحلیل با وارد کردن Scanpy آغاز می‌شود و سپس نمونه 'Parent_Visium_Human_Glioblastoma' با تابع 'sc.datasets.visium_sge' بارگذاری می‌شود. خروجی یک شیء 'AnnData' است که قالب اصلی Scanpy برای داده‌های تک‌سلولی و فضایی محسوب می‌شود. داده اولیه شامل ۳۴۶۸ Spot و ۳۶۶۰۱ ژن است. هر Spot در Visium می‌تواند RNA چند سلول مجاور را شامل شود و بنابراین معادل یک سلول منفرد نیست.

در 'adata.X' ماتریس بیان ژن ذخیره می‌شود؛ سطرها Spot‌ها و ستون‌ها ژن‌ها هستند. 'adata.obs' متادیتای Spot‌ها، از جمله 'in_tissue' و مختصات شبکه آرایه را نگه می‌دارد. 'adata.var' شامل اطلاعات ژن‌ها مانند شناسه ژن، نوع Feature و Genome است. مختصات مکانی واقعی Spot‌ها در 'adata.obsm["spatial"]' قرار دارد و اطلاعات تصویر بافت، مقیاس‌ها و داده‌های مرتبط با Visium در 'adata.uns["spatial"]' ذخیره می‌شود.

در داده اولیه هشدار تکراری بودن بعضی نام‌های ژن دیده شد. برای جلوگیری از خطاهای ایندکس‌گذاری، دستور 'adata.var_names_make_unique()' استفاده شد. از نظر طراحی بهتر است این دستور بلافاصله پس از بارگذاری داده اجرا شود، نه در میانه Notebook.

```
import scanpy as sc
adata = sc.datasets.visium_sge(sample_id="Parent_Visium_Human_Glioblastoma")
adata.var_names_make_unique()
```

۲. کنترل کیفیت و ژن‌های میتوکندریایی

مرحله بعدی ارزیابی کیفیت داده است. ابتدا ژن‌هایی که نام آن‌ها با `MT` شروع می‌شود به عنوان ژن‌های میتوکندریایی علامت‌گذاری می‌شوند. سپس `sc.pp.calculate\_qc\_metrics` چند شاخص مهم برای هر Spot محاسبه می‌کند. `total\_counts` مجموع Counts یا UMI‌های ثبت‌شده در یک Spot را نشان می‌دهد، `n\_genes\_by\_counts` تعداد ژن‌های شناسایی‌شده در آن Spot است و `pct\_counts\_mt` درصد Counts مربوط به ژن‌های میتوکندریایی را گزارش می‌کند.

این شاخص‌ها برای تشخیص Spot‌های کم‌کیفیت یا غیرعادی استفاده می‌شوند. Spot با Counts بسیار پایین ممکن است اطلاعات کافی نداشته باشد. Counts بسیار بالا می‌تواند نشان‌دهنده یک نقطه غیرعادی یا ترکیب شدید سلولی باشد. درصد بالای RNA میتوکندریایی نیز در بسیاری از تحلیل‌های transcriptomics به عنوان نشانه احتمالی کیفیت پایین در نظر گرفته می‌شود. قبل از تعیین آستانه‌ها، توزیع `total\_counts` و `n\_genes\_by\_counts` با Histogram بررسی شده است.

```
adata.var["mt"] = adata.var_names.str.startswith("MT-")
sc.pp.calculate_qc_metrics(adata, qc_vars=["mt"], inplace=True)
```

۳. فیلتر کردن Spot‌ها و ژن‌ها

در مرحله Filtering، ابتدا Spot‌هایی با کمتر از ۲۰۰۰ Count و بیشتر از ۲۰۰۰۰ Count حذف می‌شوند. سپس فقط Spot‌هایی نگه داشته می‌شوند که درصد بیان ژن‌های میتوکندریایی آن‌ها کمتر از ۲۰ درصد باشد. پس از این مرحله تعداد Spot‌ها از ۳۴۶۸ به ۲۸۷۰ کاهش یافته است؛ یعنی حدود ۵۹۸ Spot یا تقریباً ۱۷ درصد داده اولیه کنار گذاشته شده است.

سپس `sc.pp.filter\_genes(adata, min\_cells=10)` ژن‌هایی را حذف می‌کند که در کمتر از ۱۰ Observation بیان شده‌اند. در این پروژه منظور عملی Observation همان Spot است، حتی اگر نام پارامتر `min\_cells` باشد. با این فیلتر تعداد ژن‌ها از ۳۶۶۰۱ به ۱۸۶۱۸ می‌رسد. حذف ژن‌های بسیار Sparse نویز و هزینه محاسباتی را کاهش می‌دهد. نتیجه این مرحله یک ماتریس تمیزتر با ابعاد تقریبی ۲۸۷۰ Spot در ۱۸۶۱۸ ژن است.

```
sc.pp.filter_cells(adata, min_counts=2000)
sc.pp.filter_cells(adata, max_counts=20000)
adata = adata[adata.obs["pct_counts_mt"] < 20]
sc.pp.filter_genes(adata, min_cells=10)
```

۴. نرمال‌سازی و تبدیل لگاریتمی

پس از QC، داده با `sc.pp.normalize\_total` نرمال می‌شود. علت این مرحله آن است که تعداد کل Transcript‌های ثبت‌شده در Spot‌ها یکسان نیست. اگر این تفاوت اصلاح نشود، Spot‌هایی با عمق توالی‌یابی بیشتر ممکن است صرفاً به دلیل تعداد Reads بالاتر، از نظر بیان همه ژن‌ها بزرگتر دیده شوند. نرمال‌سازی Total Count تلاش می‌کند مقیاس Spot‌ها را قابل‌مقایسه کند.

سپس `sc.pp.log1p(adata)` تبدیل `log(1+x)` را اعمال می‌کند. تبدیل لگاریتمی دامنه مقادیر را فشرده می‌کند و اثر ژن‌های با Expression بسیار بالا را کاهش می‌دهد. نکته مهم این است که از این نقطه به بعد `adata.X` دیگر Raw Counts نیست؛ بلکه مقادیر نرمال‌شده و Log-transformed را نگه می‌دارد. بنابراین در بخش SpatialDE نام متغیر `counts` از نظر مفهومی دقیق نیست و نامی مانند `expr` یا `expression\_df` مناسب‌تر بود.

```
sc.pp.normalize_total(adata, inplace=True)
sc.pp.log1p(adata)
```

۵. انتخاب ژن‌های بسیار متغیر

برای استخراج سیگنال‌های informative، ژن‌های Highly Variable با `sc.pp.highly\_variable\_genes` و روش `seurat` مشخص می‌شوند. در بخش اصلی Clustering تعداد ۲۰۰ ژن بسیار متغیر انتخاب شده است. ایده این است که همه ۱۸ هزار ژن به یک اندازه برای تفکیک Spot‌ها مفید نیستند؛ بسیاری از ژن‌ها تقریباً ثابت، کم‌بیان یا نویزی‌اند. HVG‌ها ژن‌هایی هستند که تغییرپذیری آن‌ها در میان Spot‌ها نسبت به سطح بیانشان قابل توجه است و بنابراین برای یافتن ساختار پنهان داده مناسب‌ترند.

در این Notebook بعداً برای SpatialDE دوباره HVG‌ها با `n\_top\_genes=2000` محاسبه می‌شوند. این دو انتخاب هدف‌های متفاوت دارند: ۲۰۰ ژن برای تحلیل کاهش بعد و خوشه‌بندی اولیه و ۲۰۰۰ ژن برای محدود کردن فضای جست‌وجوی SpatialDE. این کار از نظر محاسباتی

منطقی است، اما باید در گزارش روش ذکر شود تا خواننده تصور نکند پارامترها به‌طور تصادفی تغییر کرده‌اند. رفتار دقیق PCA در استفاده از ستون `highly\_variable` نیز به نسخه Scanpy وابسته است؛ بنابراین در یک نسخه نهایی بهتر است این انتخاب به‌صورت صریح در پارامترهای PCA یا Subsetting مشخص شود.

۶. PCA، گراف همسایگی و UMAP

پس از آماده‌سازی داده، `sc.pp.pca(adata)` تحلیل مؤلفه‌های اصلی را اجرا می‌کند. PCA یک روش خطی کاهش بعد است و ترکیب‌هایی از ژن‌ها را پیدا می‌کند که بیشترین واریانس داده را توضیح می‌دهند. به جای کار مستقیم در فضای هزاران ژن، هر Spot با مجموعه‌ای کوچک‌تر از مؤلفه‌های اصلی نمایش داده می‌شود.

سپس `sc.pp.neighbors(adata)` گراف همسایگی را در فضای transcriptomic می‌سازد. این گراف بر اساس شباهت بیان ژن است، نه مجاورت فیزیکی روی بافت. بعد `sc.tl.umap(adata)` ساختار چندبعدی را به دو بعد فشرده می‌کند تا مشاهده خوشه‌ها آسان شود. UMAP ابزار Visualization است و فاصله دو نقطه روی UMAP را نباید به‌عنوان فاصله فیزیکی در بافت تفسیر کرد.

```
sc.pp.pca(adata)
sc.pp.neighbors(adata)
sc.tl.umap(adata)
```

۷. خوشه‌بندی Leiden و تفسیر خوشه‌ها

`sc.tl.leiden(adata, key\_added="clusters")` الگوریتم Leiden را روی گراف همسایگی اجرا می‌کند و ۱۱ خوشه با برچسب‌های صفر تا ده تولید شده است. Leiden یک روش بدون نظارت برای Community Detection در گراف است. در اینجا Nodeها Spotها و Edgeها نشان‌دهنده شباهت transcriptomic هستند. بنابراین هر Cluster مجموعه‌ای از Spotهاست که از نظر بیان ژنی به یکدیگر شبیه‌ترند.

مهم است که این ۱۱ خوشه به‌طور خودکار معادل Cell Type، ناحیه پاتولوژیک یا زیرنوع Classical، Mesenchymal و Proneural نیستند. برای Annotation زیستی آن‌ها به Marker Gene، منابع مرجع یا تحلیل‌های تکمیلی نیاز است. UMAP با رنگ `total\_counts`، `n\_genes\_by\_counts` و `clusters` رسم شده تا بررسی شود آیا ساختار خوشه‌ای با شاخص‌های فنی QC همبستگی شدید دارد یا خیر.

```
sc.tl.leiden(adata, key_added="clusters")
```

۸. نگاشت خوشه‌ها و شاخص‌های QC روی بافت

یکی از مزیت‌های اصلی داده Visium این است که نتایج تحلیل transcriptomic را می‌توان روی تصویر H&E بافت برگرداند. با `sc.pl.spatial` ابتدا `total\_counts` و `n\_genes\_by\_counts` روی تصویر ترسیم شده‌اند. این نمایش نشان می‌دهد کیفیت یا غنای Transcript در سطح بافت چگونه است و بعضی نواحی Counts یا تعداد ژن‌های شناسایی‌شده بیشتری دارند.

سپس خوشه‌های Leiden با رنگ‌های مجزا روی همان تصویر نشان داده شده‌اند. این مرحله نشان می‌دهد Clusterها تا چه حد در بافت Spatial Coherence دارند. در Notebook اندازه Spot با `size=0.5`، `1` و `2` مقایسه شده است. این مقایسه صرفاً مربوط به Visualization است؛ Size کوچک‌تر جزئیات Histology را بهتر نشان می‌دهد و Size بزرگ‌تر Assignment خوشه‌ها را واضح‌تر می‌کند.

۹. تحلیل بیان افتراقی و Marker Gene

برای مشخص کردن ژن‌هایی که هر خوشه را از سایر خوشه‌ها متمایز می‌کنند، `sc.tl.rank\_genes\_groups` با روش `t-test` اجرا شده است. این بخش یک آزمون آماری بیان افتراقی است و هدف آن یافتن ژن‌هایی است که در یک Cluster نسبت به گروه‌های دیگر Expression بالاتری دارند. سپس برای Cluster شماره ۱، ده ژن برتر با Heatmap نمایش داده شده‌اند. در خروجی ژن‌هایی مانند PTN، S100B، FABP5، MT3، TIMP1 و DBI، APLP2، MT2A، METTL7B دیده می‌شوند.

Heatmap به ما اجازه می‌دهد ببینیم این ژن‌ها در Cluster هدف و سایر Clusterها چگونه بیان می‌شوند. مشاهده Markerها به‌تنهایی برای نامگذاری قطعی Cluster کافی نیست. هشدار مربوط به Dendrogram در این مرحله خطا نیست؛ Scanpy برای مرتب‌سازی گروه‌ها Dendrogram موردنیاز را در صورت نبودن ایجاد می‌کند.

```
sc.tl.rank_genes_groups(adata, "clusters", method="t-test")
sc.pl.rank_genes_groups_heatmap(adata, groups="1", n_genes=10, groupby="clusters")
```

۱۰. بررسی فضایی EGFR

ژن `EGFR` به‌طور جداگانه روی بافت نمایش داده شده و در کنار نقشه Clusterها قرار گرفته است. هدف این است که بررسی شود آیا Expression این ژن در سراسر بافت یکنواخت است یا در نواحی خاص افزایش پیدا می‌کند. در تصویر حاصل، الگوی EGFR ناهمگن است و نقاط با Expression بیشتر در مناطق خاص مشاهده می‌شوند.

این مرحله یک تحلیل اکتشافی است و نباید از روی همپوشانی بصری نتیجه گرفت که یک Cluster خاص حتماً یک Subtype مولکولی یا ناحیه توموری مشخص است. برای چنین ادعایی به آزمون آماری و Validation نیاز است.

۱۱. SpatialDE و دلیل سنگین‌بودن محاسبات

بخش SpatialDE برای یافتن Spatially Variable Genes استفاده شده است؛ یعنی ژن‌هایی که تغییرات Expression آنها به مکان Spot روی بافت وابسته است و الگوی فضایی آنها تصادفی نیست. این هدف با Differential Expression متفاوت است. آزمون Marker Gene می‌پرسد «کدام ژن بین Clusterها متفاوت است؟» اما SpatialDE می‌پرسد «کدام ژن در صفحه بافت دارای ساختار فضایی معنادار است؟».

`SpatialDE.run(coord, counts)` از مدل‌سازی آماری فضایی و ساختارهای covariance/Gaussian-process-like استفاده می‌کند و برای ژن‌های متعدد چند مدل یا الگوی فضایی را ارزیابی می‌کند. اجرای آن روی ۱۸۶۱۸ ژن می‌تواند زمان‌بر باشد. در اجرای اولیه، پردازش تمام ژن‌ها ده‌ها دقیقه طول می‌کشد.

۱۲. بهینه‌سازی SpatialDE با ۲۰۰۰ ژن

برای کاهش زمان، ابتدا ۲۰۰۰ Highly Variable Gene انتخاب شده و `adata\_svg` فقط با این ژن‌ها ساخته شده است. در نتیجه ماتریس ورودی SpatialDE از حدود ۱۸۶۱۸×۲۸۷۰ به ۲۰۰۰×۲۸۷۰ کاهش یافته است. سپس `adata\_svg.X.toarray()` ماتریس Sparse را به Dense DataFrame تبدیل می‌کند و مختصات X و Y از `adata\_svg.obsm["spatial"]` استخراج می‌شوند. برای کنترل پیشرفت نیز `tqdm` به چهار مرحله Pipeline اضافه شده است.

این Optimization هزینه محاسباتی را به‌شدت کم می‌کند، اما یک Trade-off علمی دارد: SpatialDE دیگر کل Transcriptome را بررسی نمی‌کند، بلکه فقط بین ۲۰۰۰ HVG به دنبال SVG می‌گردد. بنابراین عبارت دقیق در گزارش باید این باشد که «ژن‌های فضایی در میان ۲۰۰۰ ژن بسیار متغیر غربال شدند». برای تحلیل مقاله‌ای می‌توان تعداد ژن‌ها را بیشتر کرد یا Filtering زیستی مناسب‌تری انجام داد.

```
sc.pp.highly_variable_genes(adata, n_top_genes=2000)
adata_svg = adata[:, adata.var["highly_variable"]].copy()
results = SpatialDE.run(coord, counts)
```

۱۳. ادغام و رتبه‌بندی نتایج SpatialDE

پس از اتمام SpatialDE، ستون `g` که نام ژن است به Index تبدیل می‌شود و نتایج با `adata.var` به‌صورت Left Join ادغام می‌شوند. چون فقط ۲۰۰۰ ژن ارزیابی شده‌اند، ژن‌های دیگر در ستون‌های SpatialDE مقدار `NaN` خواهند داشت.

سپس `results.sort\_values("qval").head(10)` ده ژن با کمترین q-value را نشان می‌دهد. q-value نسخه اصلاح‌شده Significance پس از در نظر گرفتن Multiple Testing است؛ بنابراین q-value کوچک‌تر شواهد بیشتری برای وجود الگوی فضایی فراهم می‌کند. در ادامه ژن‌هایی مانند `SLC9A3R2` و `COX20` روی تصویر بافت نمایش داده شده‌اند تا الگوی مکانی Expression آنها به‌صورت بصری ارزیابی شود. از روی اسکرین‌شات‌ها نمی‌توان با قطعیت ادعا کرد این دو ژن رتبه اول و دوم SpatialDE بوده‌اند؛ فقط مشخص است که پس از تحلیل برای Visualization انتخاب شده‌اند.

```
results = results.set_index("g", drop=False)
adata.var = adata.var.join(results.drop(columns="g", how="left"))
results.sort_values("qval").head(10)
```

۱۴. تحلیل پنج ژن گزارش‌شده در ادبیات GBM

در بخش پایانی، یک مطالعه قبلی معرفی شده که با XGBoost سه زیرنوع Molecular، Mesenchymal و Classical Proneural را بررسی کرده و پنج ژن `PLAUR`، `NKAIN1`، `UBE2E2`، `F13A1`، `RNFI149` را به‌عنوان ژن‌های مهم گزارش

کرده است. در Notebook حاضر XGBoost آموزش داده نشده و هیچ Classification زیرنوعی انجام نشده است. این ژن‌ها فقط از Literature انتخاب و Expression فضایی آن‌ها روی بافت ترسیم شده است.

این تفاوت در گزارش علمی بسیار مهم است. بیان درست این است که پروژه «Spatial expression patterns of previously reported GBM subtype-associated genes» را بررسی می‌کند، نه اینکه خودش Subtype Prediction انجام داده باشد. برای نتیجه‌گیری درباره Subtype ها به Validation مستقل نیاز است.

۱۵. تفسیر کلی نتایج

در مجموع، Pipeline نشان می‌دهد بافت GBM از نظر Transcriptomic ناهمگن است. Leiden یازده گروه محاسباتی از Spot ها ایجاد کرده و نگاشت این گروه‌ها روی تصویر بافت نشان می‌دهد بخشی از این تفاوت‌ها ساختار مکانی دارند. UMAP نیز جدایی نسبی بعضی گروه‌ها را در فضای بیان ژن نشان می‌دهد. Marker Gene Analysis ژن‌هایی را معرفی می‌کند که می‌توانند برای تفسیر زیستی Cluster ها استفاده شوند و نمایش EGFR نشان می‌دهد Expression یک ژن مرتبط با GBM نیز در سراسر بافت یکنواخت نیست.

SpatialDE لایه دیگری از اطلاعات فراهم می‌کند و ژن‌هایی را جست‌وجو می‌کند که تغییراتشان با موقعیت فضایی مرتبط است. در نهایت، Visualization پنج ژن منتخب از Literature، ارتباط پروژه با مطالعات قبلی GBM را تقویت می‌کند. خروجی فعلی اکتشافی است و نباید به عنوان تشخیص Cell Type یا نتیجه بالینی قطعی تفسیر شود.

۱۶. نقاط قوت، محدودیت‌ها و پیشنهادها

نقطه قوت اصلی پروژه این است که یک Workflow نسبتاً کامل از QC تا تحلیل Spatial را روی یک داده واقعی Visium اجرا می‌کند و فقط به UMAP محدود نمی‌شود. ترکیب Overlay، Differential Expression، Clustering روی Histology و SpatialDE تصویر جامع‌تری از بافت ارائه می‌دهد.

در مقابل، چند محدودیت وجود دارد. فقط یک نمونه بافتی تحلیل شده و بنابراین تعمیم نتایج به بیماران دیگر ممکن نیست. Cluster ها Annotation زیستی رسمی ندارند. SpatialDE روی کل Transcriptome اجرا نشده است. پارامترهای QC و تعداد HVG ها Validation جداگانه ندارند. همچنین برای نسبت‌دادن Subtype های GBM فقط پنج ژن منفرد نمایش داده شده‌اند و Signature-level analysis وجود ندارد. برای تقویت پروژه می‌توان Deconvolution، Neighborhood Enrichment، Moran's I، Pathway Enrichment، Annotation، Subtype Signature Scoring را اضافه کرد.

جمع‌بندی

این Notebook یک Pipeline محاسباتی منسجم برای تحلیل Spatial Transcriptomics گلیوبلاستوما ارائه می‌دهد. داده 10x Visium ابتدا از نظر کیفیت ارزیابی و فیلتر شده، سپس نرمال‌سازی و Log Transformation انجام شده است. با استفاده از ژن‌های متغیر، PCA، گراف همسایگی، UMAP و Leiden، ساختار transcriptomic داده بررسی و یازده Cluster شناسایی شده‌اند. این Cluster ها و شاخص‌های QC روی تصویر Histology نگاشت شده‌اند. سپس Marker Gene ها با t-test بررسی، EGFR و چند ژن منتخب به‌صورت فضایی نمایش داده شده و SpatialDE برای کشف الگوهای بیان مکانی اجرا شده است.

از نظر روش‌شناسی، این پروژه بیشتر در حوزه Computational Biology و Spatial Transcriptomics قرار می‌گیرد تا Deep Learning. مهم‌ترین مرحله محاسباتی SpatialDE است که با کاهش تعداد ژن‌های ورودی به ۲۰۰۰ HVG بهینه شده است. خروجی فعلی پایه مناسبی برای GitHub و یادگیری عملی Spatial Transcriptomics است.

خلاصه روش‌ها

هدف	روش	مرحله
شناسایی Spot های کم‌کیفیت و Outlier	Scanpy QC metrics	QC
کاهش اثر Sequencing depth و چولگی	normalize_total + log1p	Normalization
تمرکز روی ژن‌های informative	Highly Variable Genes	Feature Selection

Dimensionality Reduction	PCA / UMAP	خلاصه‌سازی و نمایش ساختار داده
Graph Clustering	Leiden	کشف گروه‌های transcriptomic بدون نظارت
Differential Expression	t-test	یافتن Marker Gene های خوشه‌ها
Spatial Analysis	SpatialDE	شناسایی ژن‌های دارای الگوی فضایی غیر تصادفی

Shayanrehva1999@gmail.com